


PERCEPTRON SIMPLE



$$O_i = g(h_i) = g(\sum w_{ik} \xi_k)$$

PERCEPTRON SIMPLE

$$O_i = g(h_i) = g\left(\sum_k w_{ik} \xi_k\right)$$

Convención: los umbrales equivalen a una neurona $\xi_0 = -1$ y $w_{i0} = \theta_i$

$$O_i = g\left(\sum_{k=0}^N w_{ik} \xi_k\right) = g\left(\sum_{k=1}^N w_{ik} \xi_k - \theta_i\right)$$

$O_i^\mu = \zeta_i^\mu$ es nuestra condición de aprendizaje

$$O_i^\mu = g(h_i^\mu) = g\left(\sum_k w_{ik} \xi_k^\mu\right)$$

Ξ, O, Z booleanos o continuos

UNIDADES UMBRAL O ESCALON

$$g(h) = \text{sgn}(h)$$

Sup. $\zeta_i = \pm 1 \rightarrow$ buscamos $\text{sgn}(\mathbf{w} \cdot \boldsymbol{\xi}_\mu) = \zeta^\mu$ para cada patrón de aprendizaje

= proyecciones de ξ sobre w coincidan en signo con $\zeta \rightarrow$ la condición $w \cdot \xi = 0$ separa ambas clases (plano al origen, ortogonal a w) (a)

O, introduciendo el c.v.: $\mathbf{x}_k^\mu \equiv \zeta^\mu \boldsymbol{\xi}_k^\mu \quad \mathbf{x}^\mu \equiv \zeta^\mu \boldsymbol{\xi}^\mu$

nuestra condición se reexpresa (b): $\mathbf{w} \cdot \mathbf{x}^\mu > 0$





TABLE 5.1 AND function

ξ_1	ξ_2	ζ
0	0	-1
0	1	-1
1	0	-1
1	1	+1

El problema será resoluble si y sólo si es linealmente separable = existe un plano en el espacio de Ξ que separe los patrones.

Reescrito con umbral: $O = \text{sgn}(W \xi - W_0) \rightarrow$ el plano N-1 dimensional que separa es $W \xi - W_0$ (W_0 ordenada al origen del plano)

ALGORITMO DE APRENDIZAJE

$$W_{ik}(n+1) = W_{ik}(n) + \Delta_{ik}(n) \quad \text{con} \quad \Delta_{ik}(n) = \eta (\zeta_i - O_i) \xi_k$$

Más general:

$$\Delta w_{ik} = \eta \Theta(N\kappa - \zeta_i^\mu h_i^\mu) \zeta_i^\mu \xi_k^\mu$$



i.e la condición de aprendizaje sería

$$\zeta_i^\mu h_i^\mu \equiv \zeta_i^\mu \sum_k w_{ik} \xi_k^\mu > N\kappa \quad \text{en lugar de } > 0$$

Con una sola salida:

$$\mathbf{w} \cdot \mathbf{x}^\mu > N\kappa \quad \Delta \mathbf{w} = \eta \Theta(N\kappa - \mathbf{w} \cdot \mathbf{x}^\mu) \mathbf{x}^\mu$$

→ todos los \mathbf{x} a más de $N\kappa/|\mathbf{w}|$ del plano ortogonal a \mathbf{w} que separa



TEOREMA DE CONVERGENCIA (Rosenblatt)

Para un problema linealmente separable, la solución mediante la regla de aprendizaje se obtiene en un número finito de pasos.

DIFICULTAD DE UN PROBLEMA (Hertz)



$$D(\mathbf{w}) = \frac{1}{|\mathbf{w}|} \min_{\mu} \mathbf{w} \cdot \mathbf{x}^{\mu}$$

$$D_{\max} \equiv \max_{\mathbf{w}} D(\mathbf{w})$$

Interpretación: qué tan lejos está, para un \mathbf{w} , el \mathbf{x} más alejado del plano ortogonal a \mathbf{w} , maximizado sobre todos los \mathbf{w} .

D_{\max} grande \rightarrow problema fácil

$D_{\max} < 0 \rightarrow$ problema sin solución E.g.: $D_{\max}(\text{AND}) = 1/\sqrt{17}$ $D_{\max}(\text{XOR}) = -1/\sqrt{3}$




PERCEPTRONES Y REGLA DE HEBB

Cuando un axón de una célula A está suficientemente próximo para excitar a una célula B o toma parte en su disparo de forma persistente, tiene lugar algún proceso de crecimiento o algún cambio metabólico en una de las células, o en las dos, de tal modo que la eficiencia de A, como una de las células que desencadenan el disparo de B, se ve incrementada.

D. Hebb, *Organization of behaviour*, 1949

Es el *Postulado de Hebb*.

*Apliquémoslo al **experimento de Pavlov**: condicionamiento estímulo-respuesta, vía un perceptrón simple*



Si bien W_2 no es al principio lo suficientemente excitatorio por sí solo, como

$$\Delta W_2 \approx \zeta \xi_2$$

si presentamos persistentemente la asociación (ξ, ζ) al sistema, el peso w_2 va a llegar a reforzarse hasta el punto de ser suficiente sin ξ_1

Aprendizaje = modificación en las sinapsis

Hebb: ¿aumento del área de la unión sináptica? o (más reciente)
¿ incremento de la velocidad con que se libera el neurotransmisor en la célula presináptica?

UNIDADES LINEALES

$g(h) = h$ y propongamos:

$$E[\mathbf{w}] = \frac{1}{2} \sum_{\mathbf{i}\mu} (\zeta_{\mathbf{i}}^{\mu} - O_{\mathbf{i}}^{\mu})^2 = \frac{1}{2} \sum_{\mathbf{i}\mu} \left(\zeta_{\mathbf{i}}^{\mu} - \sum_{\mathbf{k}} w_{\mathbf{i}\mathbf{k}} \xi_{\mathbf{k}}^{\mu} \right)^2 .$$

Descenso por gradiente:

$$\begin{aligned} \Delta w_{\mathbf{i}\mathbf{k}} &= -\eta \frac{\partial E}{\partial w_{\mathbf{i}\mathbf{k}}} \\ &= \eta \sum_{\mu} (\zeta_{\mathbf{i}}^{\mu} - O_{\mathbf{i}}^{\mu}) \xi_{\mathbf{k}}^{\mu} . \end{aligned}$$

$$\Delta w_{\mathbf{i}\mathbf{k}} = \eta (\zeta_{\mathbf{i}}^{\mu} - O_{\mathbf{i}}^{\mu}) \xi_{\mathbf{k}}^{\mu}$$

$$\Delta w_{\mathbf{i}\mathbf{k}} = \eta \delta_{\mathbf{i}}^{\mu} \xi_{\mathbf{k}}^{\mu}$$

$\delta_{\mathbf{i}}^{\mu} = \zeta_{\mathbf{i}}^{\mu} - O_{\mathbf{i}}^{\mu}$.es el error en la salida i cuando se presenta la entrada $\mu \rightarrow$ regla delta (nuevamente, idem unidades escalón) \rightarrow coinciden el enfoque hebbiano y el del gradiente


$E(\mathbf{w})$ es forma cuadrática \rightarrow único mínimo

Si los $\{\xi\}$ del conjunto de entrenamiento son l.i. (=hay solución)

\rightarrow mínimo en $E = 0$

Toda dirección ξ ortogonal a $\{\xi\}$ (patrones del conjunto de aprendizaje)

$\rightarrow E(\mathbf{w})$ constante



- Cualquier componente de los pesos ortogonal a los $\{\xi\}$ no es cambiado por el aprendizaje

- Siempre se llega a una solución con η suficientemente pequeño

UNIDADES NO LINEALES

y continuas (diferenciables) en general

$$E[\mathbf{w}] = \frac{1}{2} \sum_{i\mu} (\zeta_i^\mu - O_i^\mu)^2 = \frac{1}{2} \sum_{i\mu} \left[\zeta_i^\mu - g\left(\sum_k w_{ik} \xi_k^\mu\right) \right]^2.$$

$$\frac{\partial E}{\partial w_{ik}} = - \sum_{\mu} [\zeta_i^\mu - g(h_i^\mu)] g'(h_i^\mu) \xi_k^\mu$$

$$\rightarrow \Delta w_{ik} = \eta \delta_i^\mu \xi_k^\mu, \text{ con } \delta_i^\mu = [\zeta_i^\mu - O_i^\mu] g'(h_i^\mu) \quad \text{cambio debido al patrón } \mu$$

*Para sigmoideas típicas : $g'(h)$ grande cuando $|h|$ pequeño
 $g'(h) \rightarrow 0$ cuando $h \rightarrow +\infty$ o $-\infty$*

\rightarrow se cambian las conexiones que alimentan entradas con h_i pequeño (las "indecisas")

Típicamente:

$$g(h) = f_{\beta}(h) = \frac{1}{1 + \exp(-2\beta h)} \quad g'(h) = 2\beta g(1 - g)$$
$$g(h) = \tanh \beta h \quad g'(h) = \beta(1 - g^2)$$

→ *no hace falta recalcular $g'(h_i)$ cuando ya se ha calculado $O_i = g(h_i)$*

Condición de existencia de solución: **independencia lineal**

ya que g inversible $\rightarrow g(h) = \zeta \leftrightarrow h = g^{-1}(\zeta)$

Convergencia del descenso por gradiente: ahora puede haber **mínimos locales** (además del global en $E = 0$, si lo hay), si los valores objetivo caen fuera del rango de g .


UNA APLICACION: RECONOCIMIENTO DE PATRONES



$(-1, -1, -1)$



$(-1, -1, 1)$



$(-1, 1, -1)$



$(-1, 1, 1)$



$(1, -1, -1)$



$(1, -1, 1)$



$(1, 1, -1)$



$(1, 1, 1)$